

Лабораторна робота №_2

СТАТИСТИЧНЕ НАВЧАННЯ ЗА BIG DATA TIME SERIES

Мета роботи:

Виявити дослідити та узагальнити особливості реалізації процесів статистичного навчання із застосуванням методів обробки Big Data масивів з використанням можливостей мови програмування Python.

I. SKILLS, які прокачуємо.

1. Очищення вхідних даних від аномальних вимірів.
2. Оцінювання якості та оптимізація математичних моделей вхідних даних.
3. Статистичне навчання за методом найменших квадратів (LSM) – поліноміальна регресія.
4. Рекурентне згладжування динамічних процесів з використанням алгоритмів фільтрації Калмана (alfa-beta, alfa-beta-gamma фільтри).
5. Статистичне навчання із застосуванням нелінійних R&D моделей.
6. R&D процеси у визначенні та реалізації етапів статистичного навчання.
7. Прогнозування (екстраполяція) параметрів досліджуваного процесу за «навченою» статистичною моделлю.
8. Візуалізація результатів розрахунків.
9. Верифікація розроблених скриптових реалізацій.
10. Опанування функціоналу бібліотек: Numpy, pandas, matplotlib, bs4, requests, json.
11. Самостійне опанування методів статистичного навчання бібліотек: Numpy; statsmodels; scikit-learn.

II. Корисні ресурси.

Матеріали Лекцій №3,4,5 курсу.

Навчально-методичний комплекс дисципліни:

<https://drive.google.com/drive/folders/1CzOKX4s4-9ddY8RzGV2twbPVbMxGUpkd?usp=sharing>
<https://classroom.google.com/u/5/c/Nzc0NTY0Njk3MDU1>

Література:

William McKinney Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython.

Plas J. Wander. Python Data Science.

Sebastian Raska, Vahid Mirjalili. Python and machine learning.

Plas J. Wander. Python Data Science.

Prateek Joshi Artificial Intelligence applications with Python.

Корисні ресурси / бібліотеки:

<https://www.kaggle.com/>
<https://github.com/PacktPublishing/Artificial-Intelligence-with-Python>
<https://scapy.net/>
<https://developers.google.com/optimization>
<https://www.tensorflow.org/>
<https://scikit-learn.org/stable/modules/sgd.html#regression>
<https://keras.io/>
<https://opencv.org/>

Статистичне навчання (МНК / регресія / поліном) в пакетах:

<https://numpy.org/doc/stable/reference/generated/numpy.polyfit.html>

<https://www.statsmodels.org/stable/examples/notebooks/generated/ols.html>

<https://scikit-learn.org/stable/modules/sgd.html#regression>

Виявлення аномальних вимірів із Python:

<https://towardsdatascience.com/pyod-a-unified-python-library-for-anomaly-detection-3608ec1fe321>

<https://blog.floydhub.com/introduction-to-anomaly-detection-in-python>

<https://cnvrg.io/anomaly-detection-python/>

<https://machinelearningmastery.com/model-based-outlier-detection-and-removal-in-python/>

<https://hands-on.cloud/implementing-anomaly-detection-using-python/>

<https://www.analyticsvidhya.com/blog/2021/06/univariate-anomaly-detection-a-walkthrough-in-python/>

Фільтр Калмана з Python:

<https://filterpy.readthedocs.io/en/latest/index.html#>

<https://forecastegy.com/posts/kalman-filter-for-time-series-forecasting-in-python/>

<https://medium.com/analytics-vidhya/kalman-filters-a-step-by-step-implementation-guide-in-python-91e7e123b968>

<https://pykalman.github.io/#kalman-filter-user-s-guide>

<https://arxiv.org/ftp/arxiv/papers/1204/1204.0375.pdf>

<https://pierantraining.com/kalman-filter-opencv-python-example/>

<https://thekalmanfilter.com/kalman-filter-python-example/>

<https://blog.quantinsti.com/kalman-filter/>

III. Завдання.

Реалізація проекту триває та спрямовано на збільшення функціональності програмної компоненти

Лабораторія провідної IT-компанії реалізує масштабний проект розробки універсальної платформи з обробки Big Data масиву статистичних даних поточного спостереження для виявлення закономірностей і прогнозування розвитку контрольованого процесу. Платформа передбачає розташування back-end компоненти на власному хмарному сервері з наданням повноважень користувачам заздалегідь адаптованого front-end функціоналу універсальної платформи.

Замовниками ресурсів платформи є: державні та комерційні компанії валютного трейдингу для прогнозування динаміки зміни курсу валют та ціни інших товарів; метеорологічні служби для прогнозування параметрів метеоумов; департаменти охорони здоров'я для прогнозування зміни показників епідеміологічних ситуацій тощо.

Вам, як Data Science Engineer поставлено завдання.

Розробити програмний скрипт мовою Python що реалізує функціонал:

Група вимог_1:

1. Отримання вхідних даних із властивостями, заданими в Лр_1;
2. Визначення показників якості та оптимізація моделі (вибір моделі залежно від значення показника якості). Показник якості та спосіб оптимізації обрати самостійно.
3. Статистичне навчання поліноміальної моделі за методом найменших квадратів (МНК – LSM) – поліноміальна регресія для вхідних даних, отриманих в п.1,2. Спосіб реалізації МНК обрати самостійно;
4. Прогнозування (екстраполяцію) параметрів досліджуваного процесу за «навченою» у п.5 моделлю на 0,5 інтервалу спостереження (об'єму вибірки);
7. Провести аналіз отриманих результатів та верифікацію розробленого скрипта.

Група вимог_2:

До функціоналу групи вимог 2 додати:

1. Модель вхідних даних із аномальними вимірами (якщо обрано синтезовані дані для обробки). Для реальних даних цей пункт пропустити;
2. Очищення вхідних даних від аномальних вимірів. Спосіб виявлення аномалій та очищення обрати самостійно;

Група вимог_3:

Реалізувати R&D процеси для етапів статистичного навчання.

- 3.1. Здійснити розробку власного алгоритму виявлення аномальних вимірів та / або «навчання» параметрів відомих алгоритмів «бачити» властивості статистичної вибірки.
- 3.2. Здійснити розробку власного алгоритму статистичного навчання із нелінійною за параметрами моделлю.

Завдання I рівня складності – максимально 8 балів.

Реалізувати групу вимог 1, або 2 – за власним вибором.

Завдання II рівня – максимально 10 балів.

Реалізувати групу вимог 1 та 2.

Завдання III рівня, підвищеної складності – максимально 15 балів.

Реалізувати групу вимог 1 та (або) 2 з імплементацією однієї з групи вимог 3. Докладно опитати отримані R&D рішення. Розробка власного алгоритму передбачає R&D новачію, а не використання тільки відомих рішень.

VI. Порядок виконання завдання лабораторної роботи.

- 4.1. Обрати завдання на лабораторну роботу за рівнем складності та відповідно до вказаного варіанту технічного завдання.
- 4.2. Реалізувати етап вибору / розробки / синтезу математичної моделі за якими здійснюватимуться обробка даних програмного скрипта.
- 4.3. Реалізувати етап архітектурного проектування (структурна схема /або/ діаграма класів /або/ блок-схема алгоритму). Здійснити опис функціонування результатів архітектурного проектування.
- 4.4. Розробити програму, що втілює розроблений алгоритм.
- 4.5. Провести тестування та верифікацію роботи програми
- 4.6. Реалізувати дослідження, що вказані в меті лабораторної роботи та сформулювати висновки.
- 4.7. Оформити звіт з лабораторної роботи та своєчасно представити його викладачеві.

V. Структура звіту з лабораторної роботи (див. Додаток 2).

- 5.1. Титульний аркуш, що містить інформацію: номер, тема, навчальна дисципліна, виконавець роботи, роботу прийняв.
- 5.2. Мета і завдання лабораторної роботи.
- 5.3. Результати виконання лабораторної роботи:
 - 5.3.1. Синтезована математична модель;
 - 5.3.2. Результати архітектурного проектування та їх опис;
 - 5.3.3. Опис структури проекту програми;
 - 5.3.4. Результати роботи програми відповідно до завдання (допускається у формі скриншотів);
 - 5.3.5. Програмний код, що забезпечує отримання результату (допускається у формі скриншотів).
- 5.4. Висновки.
- 5.5. Підпис виконавця, викладача, що прийняв роботу.

Аналіз та обробка часових рядів (Time Series)
(Сертифікатна програма Data Science із Sigma Software)

5.6. Звіт з лабораторної роботи оформлюється відповідно до вимог 3008:2015 «ЗВІТИ У СФЕРІ НАУКИ І ТЕХНІКИ. СТРУКТУРА ТА ПРАВИЛА ОФОРМЛЕННЯ».

Технічні вимоги до звіту: аркуш формату А4 шрифтом Times New Roman 12 pt через 1,0 інтервал. Поля: зверху - 2 см, знизу - 2 см, справа - 2 см, зліва - 2,5 см, абзац - 1,25 см.

VI. Звітність за лабораторну роботу.

Результатом виконання лабораторної роботи є:

6.1. Звіт з лабораторної роботи в електронному вигляді. Файл звіту кодується за формою:

Прізвище_Ім'я_(укр.)_номер групи_номер лр.*

6.2. Проект програми, що реалізує завдання лабораторної роботи, якій надається в формі архіву, як невід'ємний додаток звіту.

6.3. Оформлений звіт надається викладачеві в електронному вигляді кожним виконавцем індивідуально !

Своєчасним вважається надання звіту до початку заняття з наступної лабораторної роботи.

Оформлені звітні матеріали надсилаються за адресою:

agd015979@gmail.com

VII. Порядок оцінювання та захисту лабораторної роботи.

Максимальна кількість балів за лабораторні роботи (РЛ) за високим рівнем складає 90 балів, за середнім рівнем – 72 бал.

Загальний рейтинг за дисципліною

Звітність	Лр1	Лр2	Лр3	Лр4	Лр5	Лр6	Лр7	Лр8	Лр9	МКР	СУМА
Високий рівень	10	10	10	10	10	10	10	10	10	10	100
Середній рівень	8	8	8	8	8	8	8	8	8	10	82

Розподіл балів за виконання лабораторних робіт.

7.1. Якість / повнота оформлення протоколу з лабораторної роботи – 1 бал.

7.2. Своєчасний захист роботи – 1 бал.

7.3. Повнота аналізу отриманих результатів – 1 бал.

7.4. Якість та повнота виконання технічних умов завдання, функціональність розробленої технічної продукції (програмного скрипта) -5 бали.

7.5. Рівень теоретичної підготовки – 2 бали.

*** Для умов дистанційного навчання бали за теоретичну підготовленість (п.7.4) можуть нараховуватись за результатами аналізу вмісту протоколу з лабораторної роботи.

*** Для умов військового стану – своєчасність захисту лабораторної роботи (п.7.2) – не застосовується а додається до п.7.4.

професор кафедри

Олексій ПИСАРЧУК